Semana 11 · Análisis de datos

Fase de la propuesta: análisis (semana 11).

Objetivo	Calcular la energía de cada corrida, obtener la estadística descriptiva e inferencial (clásico vs híbrido, por modo de bus) y generar las figuras para la tesis.
Dedicación estimada	5–8 horas.
Antes de empezar	Campaña completa (semana 10).
Al terminar tendrán	`data/processed/` con resumen y comparaciones, y `docs/figuras/` con las figuras.

Paso 1. Ejecutar el análisis

```
cd ~/proyecto-kyber-rpi/pi && source ../src/venv/bin/activate
python3 analisis.py ../data/raw/campana_estandar_*_meta.json \
                    ../data/raw/campana_rapido_*_meta.json
```

Pasen solo los archivos de la campaña: si no indican archivos, el script toma **todos** los `campana_*_meta.json`, incluidas las pruebas de las semanas 5 a 7 (`campana_prueba_*`).

Si analizan en otra computadora con los archivos `.gz`, primero descompriman: `gunzip -k data/raw/*_potencia.csv.gz`.

Archivo	Contenido
corridas_con_energia.csv	cada corrida con su energía del handshake y de la corrida, y la marca «valida»
reposo_por_bloque.csv	P_reposo inicial y final de cada bloque, deriva y muestras por segundo
resumen.csv	n, media, desviación, IC 95 %, mediana y CV por bloque, grupo (y tamaño de mensaje)
comparaciones.csv	híbrido vs clásico: diferencia, sobrecosto %, IC 95 % bootstrap, p de Welch, p de Mann-Whitney y normalidad (Shapiro)
docs/figuras/fig1…fig6	tiempo, energía, rendimiento, tamaño del ClientHello, etapas y latencia

Paso 2. Controles de validez (antes de interpretar)

- **Exclusiones**: el script imprime cuántas corridas no son válidas y por qué. Deben ser pocas y estar explicadas en la bitácora.
- **Consistencia**: `grupo_detectado` igual a `grupo` en todas las corridas válidas; `bytes_clienthello` constante dentro de cada grupo.
- **Reposo**: en `reposo_por_bloque.csv` la deriva debería ser pequeña frente a P_reposo (del orden del 1–2 %). Si es grande, la energía de ese bloque es menos confiable: anótenlo.
- **Muestras por handshake**: `muestras_en_hs` alto (decenas o más). Con pocas muestras, la energía individual es ruidosa y conviene reportar medias con su IC.
- **Temperatura y throttling**: `pre_temp_c` estable y `post_throttled` = 0x0.

Paso 3. Cómo leer y reportar los resultados

- Reporten cada métrica como **media ± IC 95 %** (de `resumen.csv`).
- El efecto del híbrido es el **sobrecosto %** con su **IC 95 % bootstrap** (de `comparaciones.csv`). Si el intervalo no incluye 0, la diferencia es clara.
- Para la significancia: `p_welch` (no supone varianzas iguales). Si Shapiro rechaza la normalidad ($p < 0{,}05$) en algún grupo, apóyense también en `p_mann_whitney`.
- Separen siempre por **modo de bus**: la pregunta de la tesis es cómo cambia el costo del híbrido en un enlace lento, así que la comparación estándar vs rápido es parte del resultado.

Paso 4. Análisis complementarios útiles

Estos dos cálculos ayudan a explicar los resultados (cópienlos en un archivo `extra.py` dentro de `pi/`):

pi/extra.py

```
import pandas as pd
d = pd.read_csv("../data/processed/corridas_con_energia.csv")
d = d[d.valida]
# 1) ¿Cuánto cambia el handshake al pasar de 100 a 400 kbit/s, por grupo?
print(d.groupby(["grupo", "bloque"]).esp_t_hs_us.median().unstack())
# 2) ¿Qué parte del handshake es transmisión por el bus y qué parte es cómputo?
et = ["etapa1_clienthello_y_proceso_srv_us", "etapa2_envio_vuelo_srv_us",
      "etapa3_proceso_cliente_y_finished_us", "srv_cpu_us"]
print(d.groupby(["grupo", "bloque"])[et].mean().round(0))
# 3) ¿La energía sigue al tiempo? (correlación de Spearman)
print(d.groupby("grupo")[["esp_t_hs_us", "energia_hs_mJ"]].corr(method="spearman"))
```

Paso 5. Revisar las figuras

Abran cada figura de `docs/figuras/`. Verifiquen que los ejes tengan unidades, que las barras de error sean IC 95 % y que no haya etiquetas encimadas. Elijan cuáles van en el cuerpo de la tesis y cuáles en anexos, y anótenlo. Si quieren cambiar títulos o estilos, el código está en `figuras()` de `analisis.py`.

Criterio de cierre de la semana

- ☐ analisis.py ejecutado sobre los dos bloques sin errores.
- ☐ Controles de validez revisados y anotados (exclusiones, consistencia, reposo, muestras, temperatura).
- ☐ Tabla de resultados principales (media ± IC, sobrecosto % con IC, p) armada a partir de los CSV.
- ☐ Análisis complementarios ejecutados y comentados en la bitácora.
- ☐ Figuras revisadas y seleccionadas; todo en GitHub.